

Arthur Segura Ortiz Novello
Luca Ezellner Miraglia
Lucas Marques de Araujo

Inteligência para Transporte Público

São Caetano do Sul
2020

Arthur Segura Ortiz Novello
Luca Ezellner Miraglia
Lucas Marques de Araujo

Inteligência para Transporte Público

Trabalho de Conclusão de Curso apresentado à Escola de Engenharia Mauá do Centro Universitário do Instituto Mauá de Tecnologia como requisito parcial para a obtenção de título de Engenheiro de Computação.

Área de Concentração: Engenharia de Computação

Orientador Tiago Sanches da Silva
Coorientador Murilo Zanini de Carvalho

Novello, Arthur Segura

Inteligência para Transporte Público / Arthur Segura Ortiz Novello , Luca Ezellner
Miraglia , Lucas Marques de Araujo . - São Caetano do Sul: CEUN-IMT, 2020.
45 p.

Trabalho de Conclusão de Curso - Escola de Engenharia Mauá do Centro
Universitário do Instituto Mauá de Tecnologia, São Caetano do Sul, SP, 2020.

Orientador: Prof. Me. Tiago Sanches da Silva

1. dados. 2. painel de controle. 3. inteligência artificial. 4. análise de dados. I.
Miraglia, Luca Ezellner. II. Araujo, Lucas Marques. III. Instituto Mauá de Tecnologia.
Escola de Engenharia Mauá. IV. Título.

Arthur Segura Ortiz Novello
Luca Ezellner Miraglia
Lucas Marques de Araujo

Inteligência para Transporte Público

Trabalho de Conclusão de Curso aprovado como requisito parcial para a obtenção de título de Engenheiro de Computação pela Escola de Engenharia Mauá do Centro Universitário do Instituto Mauá de Tecnologia.

Área de Concentração: Engenharia de Computação

Banca examinadora:

Prof. Me. Tiago Sanches da Silva
Orientador

Prof. Murilo Zanini de Carvalho
Coorientador
Escola de Engenharia Mauá

Prof. Me. Murilo Zanini de Carvalho
Avaliador

Prof. Dr. Sergio Ribeiro Augusto
Avaliador

São Caetano do Sul, 29 de Abril de 2020.

Aos nossos pais, irmãos e irmãs, amigos e colegas de formação.

Agradecimentos

Ao nosso orientador, Prof. Me. Tiago Sanches, que nos auxiliou desde o início, que sempre nos motivou e nos ajudou a traçar um melhor caminho durante toda a elaboração do projeto. Seus conselhos, críticas, ideias e conhecimento foram fundamentais para a realização deste trabalho.

Ao Prof. Me. Murilo Zanini, nosso coorientador por estar sempre nos auxiliando quando preciso, aconselhando nos afazeres e entregas relacionadas a este trabalho.

Ao Prof. Dr. Sergio Ribeiro, pela sua paciência e presença contínua, nos assessorando, motivando e inspirando nos momentos difíceis. Seu amplo conhecimento teórico e prático também contrinuiu na elaboração deste documento, além de sua rica experiência e vivência acadêmica.

Ao Instituto Mauá de Tecnologia, por nos fornecer infraestrutura e suporte durante toda a formação acadêmica dos integrantes deste grupo ao longo de todo o período de graduação.

Aos amigos, familiares e todas as outras pessoas que também contribuíram direta ou indiretamente para o desenvolvimento deste trabalho.

“Technology will reinvent the business, but human relationships will remain the key to success”
("A tecnologia vai reinventar o negócio, mas as relações humanas continuarão a ser a chave para
o sucesso.")

Stephen Covey

Resumo

O projeto em questão tem como objetivo a criação de um dashboard que monitora as demandas das frotas de veículos, no caso as linhas de ônibus da SPTrans, empresa responsável pelos ônibus da cidade de São Paulo. Para esse monitoramento, serão utilizados dados públicos fornecidos pela SPTrans, como rotas dos ônibus, dados de GPS, linhas e paradas, por exemplo, que serão enriquecidos com outras informações, como datas e locais de eventos, situação das linhas de trens e metrô, informações meteorológicas e o trânsito na cidade.

Com posse dessas informações, o projeto também visa o desenvolvimento de um modelo de inteligência artificial que poderá ser utilizado pela equipe operacional da SPTrans para auxiliar o controle de demanda das frotas, indicando se são necessários mais ou menos ônibus em cada linha. Os dados apresentados pelo modelo também poderão ser utilizados por cidadãos comuns que procuram uma maior transparência para observar a situação das linhas e potenciais fatores que poderão alterar o fluxo normal do transporte público.

Considerando que atualmente muitos dados do transporte coletivo são públicos, mas não existe uma plataforma centralizadora dessas informações que seja capaz de auxiliar as pessoas no que diz respeito a uma visão geral das condições das linhas de ônibus, o presente trabalho pretende contribuir positivamente para melhorar a experiência dos usuários e trazer uma visão mais transparente do serviço como um todo.

Para a construção do sistema foram utilizadas ferramentas como Python, Django, Django-REST, Celery e Amazon Web Services (AWS), que possibilitaram o desenvolvimento do dashboard e todas suas funcionalidades, desde a aquisição de dados externos, até a manipulação desses dados e implantação da plataforma na nuvem.

Palavras-chaves: dados. painel de controle. inteligência artificial. análise de dados. decisão. transporte público.

Abstract

This project aims to create a dashboard that monitors the demand of vehicles in bus lines of SPTrans, the company responsible for buses in the city of São Paulo. For this monitoring, public data provided by SPTrans was used, such as bus routes, GPS data, lines and stops, for example, which will be enriched with other information, like dates and locations of events, status of train and subway lines, weather information and traffic around the city.

With this information, the project also aims to develop an artificial intelligence model that can be used by the SPTrans operational team to help control demand from fleets, indicating whether more or less buses are needed on each line. The data generated by the model can also be used by ordinary citizens who seek greater transparency to follow the situation of the lines and potential factors that may alter the normal flow of public transport.

Although a lot of public transport data is public available, there isn't a system to aggregate all this information that would be able to help people who use this kind of transport on a daily basis with a overview about the lines condition. The present work intends to contribute positively to improve the user experience and bring a more transparent and complete view of the service.

During the development, tools such as Python, Django, Django-REST, Celery and Amazon Web Services (AWS) were used, which made it possible to create a dashboard and all its features, from the acquisition of external data, to the manipulation of that data and deployment of the platform in a cloud platform.

Key-words: data. dashboard. artificial intelligence. data analysis. decision. public transportation.

Lista de ilustrações

Figura 1 – Inteligência artificial, aprendizado de máquina e aprendizado profundo . . .	20
Figura 2 – Perceptron Elementar	22
Figura 3 – Rede Neural Multicamada	23
Figura 4 – Etapas da detecção de objetos do YOLO	25
Figura 5 – Comparação do YOLO com outras ferramentas	25
Figura 6 – Ilustração da solução	28
Figura 7 – Gráficos criados pelo django-plotly-dash	30
Figura 8 – Rotas das APIs dentro da plataforma <i>web</i> disponibilizada pelo Django . . .	31
Figura 9 – Exemplo de retorno JSON do <i>endpoint</i> /api/onibus-lotacao	32

Lista de abreviaturas e siglas

API	<i>Application Programming Interface</i>
CPTM	Companhia Paulista de Trens Metropolitanos
IBGE	Instituto Brasileiro de Geografia e Estatística
IA	Inteligência Artificial
SP-Trans	São Paulo Transportes
AWS	<i>Amazon Web Services</i>
EC2	<i>Elastic Compute Cloud</i>
SQS	<i>Simple Queue Service</i>
CRUD	<i>Create, Read, Update, Delete</i>
REST	<i>Representational State Transfer</i>
OpenCV	<i>Open Source Computer Vision</i>
YOLO	<i>You Only Look Once</i>

Sumário

1	INTRODUÇÃO	13
1.1	Transporte público	13
1.2	Justificativa	14
1.3	Mercados	14
1.4	Objetivos	14
1.5	Contribuições do trabalho	15
1.6	Questão central da pesquisa e seus impactos	15
2	REVISÃO BIBLIOGRÁFICA	16
2.1	Tecnologia de Monitoramento de Ônibus	16
2.2	<i>Dashboard</i>	17
2.2.1	Uma ferramenta de apoio à decisão	17
2.2.2	Benefícios do uso para as empresas	18
2.2.3	Antecipação de problemas	18
2.2.4	Experiência de uso	19
2.3	Inteligência Artificial, Aprendizado de Máquina e Aprendizado Profundo	19
2.4	<i>Deep Learning</i> e Redes Neurais	20
2.4.1	História	20
2.4.2	Funcionamento das Redes Neurais	21
2.5	Análise de imagens de câmeras de ônibus	23
2.5.1	Deteção de objetos em tempo real com YOLO	24
2.6	Análise de Dados	26
2.6.1	Primeira fase da análise de dados	26
2.6.2	Segunda fase da análise de dados	26
2.6.3	Terceira fase da análise de dados	26
2.6.4	Análise de dados no dia a dia	27
3	METODOLOGIA	28
3.1	Aquisição de dados externos por meio de tarefas	28
3.2	Criação de gráficos com Django	29
3.3	APIs com Django REST <i>Framework</i>	30
3.4	<i>Endpoints</i>	32
3.5	Infraestrutura de nuvem	33
4	RESULTADOS OBTIDOS	35
4.1	Resultados	35
5	CONCLUSÃO E TRABALHOS FUTUROS	36

5.1	Conclusão	36
5.2	Trabalhos Futuros	36

APÊNDICES 37

	APÊNDICE A – <i>ENDPOINTS</i>	38
A.1	/api/onibus-lotacao/	38
A.2	/api/onibus-posicao/	38
A.3	/api/onibus-velocidade/	38
A.4	/api/linhas/	39
A.5	/api/paradas/	40
A.6	/api/trens/	40
A.7	/api/climatempo/	41
A.8	/api/eventos/	41
	REFERÊNCIAS	43

1 Introdução

1.1 Transporte público

O transporte público caracteriza-se como uma opção amplamente utilizada por pessoas a fim de garantirem suas necessidades de locomoção. Por possuir um preço mais acessível e muitas vezes ser mais rápido e prático, 65% da população das capitais do Brasil utiliza essa forma de transporte, como aponta um estudo realizado pelo Instituto de Pesquisa Econômica Aplicada (Ipea) (PEDUZZI, 2011).

Foi direcionado o valor de R\$ 707 milhões no ano de 2019 pela União para a área de mobilidade urbana e trânsito, como indica a Lei Orçamentária Anual (LOA nº 13.808/2019). Desse montante, especificamente para o transporte público coletivo, foram separados apenas R\$ 348 milhões, uma fatia de 0,01% do orçamento total (NTURBANO, 2019).

De acordo com uma estimativa do BNDES, em 2015, seria necessário investir mais de R\$ 234 bilhões em transporte público para resolver os problemas da área nas principais regiões metropolitanas do país, portanto, caso mantido o nível de investimento atual, levaria mais de 600 anos para atingir o montante proposto pelo BNDES (SANTOS, 2015).

Tendo em vista o baixo investimento frente a demanda, é esperado que o transporte público gere um elevado nível de insatisfação em seus usuários, o que o IPEA demonstrou em outra pesquisa realizada em 2011 e 2012, na qual o transporte público foi avaliado por mais de 60% do público como "péssimo ou ruim" (SANTOS, 2015).

Para entender a situação em que se encontra o transporte, o primeiro passo é olhar como o país se urbanizou. No último século, o Brasil passou por um intenso processo de industrialização, o que gerou um forte êxodo rural e principalmente uma migração da população do Nordeste para o Sul e Sudeste, onde se concentrou a produção industrial do país.

Esse crescimento populacional nas metrópoles foi acompanhado por uma grande valorização dos terrenos e moradias nas áreas centrais das cidades. Com isso é observado um efeito de gentrificação, afastando a classe trabalhadora para regiões mais periféricas, longe de onde se concentra a maior parte da oferta de emprego, o que gerou uma, demanda por transporte, crescente até os dias atuais. Tendo em vista esse cenário, a população começou a consumir cada vez mais carros populares, que contam com incentivo do governo para serem produzidos. Com isso, o que se vê nos ambientes urbanos são ruas congestionadas e ônibus lotados (PENA, s.d.).

1.2 Justificativa

O presente trabalho tem por motivação a grande quantidade de cidadãos de São Paulo que apresentam adversidades quando se trata da utilização dos ônibus da cidade, como o elevado tempo de espera e as altas taxas de ocupação interna, que lideram as reclamações do Reclame Aqui (DEMORA, 2020) (DEMORA, 2018). Além disso, a criação de um processo inteligente e automatizado que auxilie os gestores da SP-Trans (empresa responsável pelo gerenciamento dos transportes do município de São Paulo) no ajuste das frotas de ônibus justificam esse projeto.

1.3 Mercados

Ainda olhando para o transporte público de São Paulo, hoje o sistema todo, composto de ônibus, trens, metrô e outros modais, transporta mais de 17 milhões de passageiros diariamente na capital (G1, 2013), sendo que dessa quantidade, 7 milhões utilizam as linhas de ônibus da cidade, que hoje conta com mais de 1.300 linhas (SAMPA, 2018), sendo as principais a Terminal Bandeira / Terminal Varginha, Terminal Jardim Ingela / Metrô Santa Cruz e Hospital Itaim / Guaianazes, que juntas transportam cerca de 100 mil passageiros por dia (LOBO, 2013).

Hoje, a SPTrans disponibiliza uma API, atualizada em tempo real, com informações de localização dos veículos, velocidades, pontos de parada e quantidade de ônibus ativos. Apesar de provavelmente a empresa contar com uma solução proprietária, decidimos coletar essas informações e enriquece-las com outros dados disponíveis para desenvolver o nosso trabalho.

1.4 Objetivos

Tendo em vista o cenário apresentado, pretende-se criar um *dashboard* para centralizar informações e agilizar a tomada de decisão, tendo como base dados coletados durante os trajetos de ônibus, informações extraídas de APIs públicas e imagens de câmeras instaladas nos veículos. A ferramenta irá apoiar os gestores da SP-Trans no controle do fluxo de tráfego, analisando a disponibilidade de veículos e sugerindo uma inclusão ou remoção de carros em cada linha monitorada.

Além disso, o *dashboard* será atualizado em tempo real, exibindo gráficos e indicadores de maneira sucinta, com a possibilidade de aplicação de filtros nas consultas. Considerando o volume de passageiros para um determinado dia e horário somados a dados externos, a ferramenta irá utilizar algoritmos de inteligência artificial para identificar padrões históricos e prever futuras demandas nas frotas de ônibus, facilitando o controle do serviço e auxiliando no dia a dia do transporte urbano na cidade.

1.5 Contribuições do trabalho

Este trabalho tem como contribuição a melhoria na tomada de decisões da administradora de ônibus (SP-Trans) onde será possível, de forma centralizada, a visualização de dados e gráficos por meio de um dashboard. Além disso, pode-se citar como contribuição a diminuição do tempo de espera e ocupação dos transportes, resultando em uma melhor qualidade de vida para a população de São Paulo.

1.6 Questão central da pesquisa e seus impactos

Os benefícios esperados com esse trabalho de conclusão de curso são proporcionar uma melhor qualidade locomotiva dos ônibus de São Paulo e proporcionar uma melhor gestão aos envolvidos da SP-Trans, otimizando e inovando a forma de ver os dados.

O transporte público, mais especificamente, os ônibus, podem causar estresse. A sensação pode estar relacionada a um fator estressante, como às condições do transporte, o desconforto de estar entre muitas pessoas e o elevado tempo de espera.

Com os dados disponíveis e as aplicações de IA (Inteligência Artificial) implementadas nas câmeras dos veículos de cada linha, os gestores e responsáveis poderão ver a situação de lotação e do tempo de espera através do dashboard. Numa situação crítica, eles poderão solicitar um aumento da frota e reduzir o desconforto de andar em um veículo com excesso de pessoas além de reduzir o tempo de espera. Essas ações impactam diretamente na saúde das pessoas reduzindo o estresse gerado pelos transportes.

2 Revisão bibliográfica

2.1 Tecnologia de Monitoramento de Ônibus

De acordo com a informação exposta em uma publicação feita em 2017 pela Escola de Negócios da Universidade de Indiana, era previsto um crescimento anual de mais de 23% no mercado de *Big Data* durante o período de 2014 a 2019, com um custo de \$48,6 bilhões no último ano. Isso inclui um crescimento de 30% entre 2014 e 2015 de aparelhos conectados e dispositivos de IoT. Estes aparelhos geram uma quantidade enorme de dados valiosos para quem tiver interesse de processá-los (LEE, 2017).

Esse cenário hoje não é diferente para o setor de transporte público, com a prefeitura de Santo André capturando dados em tempo real da sua frota de ônibus, informações como bilhetagem, velocidade e paradas dos veículos, porém não utilizando a informação para a tomada de decisão.

Um exemplo de uso prático desses dados foi publicado em um artigo da IEE, para a Conferência Internacional da Logística e Transporte Avançado. Em uma colaboração entre a IBM e o Conselho da Cidade de Dublin foi realizado um projeto de cidade inteligente entre 2010 e 2013 (Ben Ayed; Ben Halima; ALIMI, 2015). A IBM passou a processar os dados gerados pela frota de ônibus, além de outras fontes, com intenção de reduzir o trânsito na cidade sem precisar alterar a sua estrutura atual, que conta com vários pontos históricos.

O início do processo se dava com informações coletadas do ônibus, como dados de GPS, velocidade, paradas e bilhetagem, e depois eram adicionadas novas informações vindas de sistemas de semáforos, *CCTV*, sistemas meteorológicos, entre outros. Todos esses dados então eram processados em um servidor da IBM e disponibilizados em mapa em tempo real do transporte público de Dublin.

Com toda essa informação processada, a cidade teve uma maior capacidade de monitorar o seu sistema de transporte público, diminuindo o tempo para uma tomada de decisão.

Outro exemplo de aplicação de tecnologia no monitoramento de transporte coletivo é do USapiens, um sistema desenvolvido por um time de pesquisa da IBM do Brasil (VIEIRA et al., 2015). Essa equipe usou dados de transporte coletivo da cidade do Rio de Janeiro para desenvolver um sistema que processa os dados recebidos pelo GPS dos ônibus e depois disso analisa-se por diversos modelos esses dados.

Para isso eles integraram os dados obtidos pelo GPS com informações disponíveis de GTFS, sigla para *General Transit Feed Specification*, que contém dados mais gerais das rotas de ônibus, como paradas e horários esperados. Feita essa integração, os dados são limpos para

prevenir problemas como latitude/longitude imprecisas ou dados com intervalo de tempo muito grande. Com os dados prontos, é feita uma comparação com a rota do GTFS, se descobre a direção do veículo e com isso tem seu trajeto normalizado em uma escala de distância e tempo acumulativas.

Com a informação normalizada, o sistema pode ajudar a responder três perguntas principais. Através de uma análise descritiva histórica podemos responder "O que aconteceu e porque?", analisando os dados em tempo real se responde "O que está acontecendo e porque?" e uma análise preditiva responde "O que vai acontecer e porquê?".

Os pesquisadores da IBM depois aplicaram esse sistema a 5 casos de estudo. O primeiro foi uma Análise de Uniformidade dos Ônibus, para evitar um agrupamento de veículos na linha, o segundo caso foi uma verificação na rotas dos ônibus, para avaliar a aderência do veículo a sua rota pré-definida, o terceiro uma análise de fluxo no trânsito, o quarto a variância do tempo de viagem do veículo, que permite avaliar a consistência da rota analisada, e para o quinto ele usaram a análise preditiva para prever o tempo de chegada do ônibus.

2.2 Dashboard

O *Dashboard*, também chamado de painel de controle, é uma ferramenta que auxilia os gestores a terem uma visão mais sistemática das principais informações do negócio. Em outras palavras, é um recurso que visa consolidar os dados de maior relevância em um painel, facilitando o processo de análise e a tomada de decisão (INTELIPOST, 2017).

O uso de planilhas e relatórios já são ultrapassados para análises de dados, não sendo suficientes para suprir as necessidades mais urgentes. Conforme a tecnologia foi evoluindo no mundo corporativo, surgiram os *dashboards* que evitam esforços desnecessários e ter uma visão mais ampla de todo o cenário corporativo para, assim, tomar decisões estratégicas e assertivas.

A visualização de dados através de *dashboards* já é uma realidade em softwares de gestão empresarial, integrando painéis de controle com inteligência artificial e fornecendo informações atualizadas automaticamente. É possível personalizá-los e comparar dados através de filtros, que facilitam análises de indicadores (TECNICON, 2019).

2.2.1 Uma ferramenta de apoio à decisão

Segundo um estudo feito pela UNINDU (The International Congress on University Industry), 83% das pessoas absorvem melhor as informações através da visão. Isso demonstra a importância do *dashboard* para tomada de decisões rápidas e melhor análise dos indicadores, melhorando metas e atingindo objetivos.

O Business Intelligence (BI), por exemplo, é uma área que exige precisão na coleta e controle das informações para gerar insights em base desta ferramenta. Os dados são agrupados em conjuntos de registros e disponibilizadas por meio de *dashboards* para mensurar o desempenho atual e futuro da empresa de acordo com o cenário. =

Além disso, os *dashboards* monitoram os dados, com o intuito de melhorar todos os processos. Eles permitem que o usuário personalize painéis e filtre informações para a visualização dos resultados, como quantidade, tempo e outras opções (TECNICON, 2019).

2.2.2 Benefícios do uso para as empresas

A aplicação dos *dashboards* na gestão empresarial traz muitos benefícios para a tomada de decisão e a visão estratégica do seu negócio.

O processo de tomada de decisões fica cada vez mais fácil através dos *dashboards*, que centralizam informações de fácil visualização e compreensão, possibilitando uma visão ampla do seu negócio.

Na gestão, é importante que todas as equipes tenham acesso aos indicadores da empresa, mantendo a transparência das informações. As ferramentas de *dashboard* tem o objetivo de facilitar a comunicação interna entre todos os profissionais.

A visualização por *dashboards* otimiza o tempo para tomarem decisões e evitarem trabalhos manuais e complexos com a organização de dados, passando a priorizar outras atividades mais relevantes.

Com as informações consolidadas em um único painel, a gestão se torna mais ágil e efetiva, possibilitando o alinhamento de estratégias e decisões para o negócio (TECNICON, 2019).

2.2.3 Antecipação de problemas

Como o *dashboard* trabalha com atualizações constantes e análises mais específicas, é mais fácil prever problemas e tendências negativas que podem vir a acontecer. Estes problemas ficam mais explícitos com o uso da tecnologia de inteligência artificial que os identifica de maneira mais fácil.

Qualquer mudança é detectada com mais simplicidade e o tempo para pensar nas possíveis soluções se torna muito maior. Isso melhora o processo de tomada de decisão e evita possíveis prejuízos (SYSTEMSAT, s.d.).

2.2.4 Experiência de uso

Uma boa interface e uma boa experiência de uso se dá pela arquitetura das informação do *dashboard*. É fundamental que seja organizado, coerente e intuitivo. O objetivo é tornar o mais fácil possível encontrar o que se procura. Através de menus, cores e símbolos é possível saber quais são as opções e deixar claro as consequências que cada ação irá gerar. Dessa forma, a experiência do usuário ao usar o *dashboard* será rápida e efetiva, atendendo suas expectativas (KLEVERTON, 2019)

2.3 Inteligência Artificial, Aprendizado de Máquina e Aprendizado Profundo

A Inteligência Artificial ganhou destaque mundialmente nos últimos anos como um importante e rentável campo da computação. Em uma análise realizada para 2035, prevê-se um impacto significativo do setor no produto acrescentado bruto dos 12 principais países desenvolvidos que compõe 50% do PIB mundial (ACCENTURE, 2016). A situação não é diferente no Brasil. Uma pesquisa realizada pela Microsoft, em 2019, revela que em um cenário de máxima utilização de inteligência artificial no Brasil, a taxa composta anual de crescimento (CAGR) do Produto Interno Bruto (PIB) pode aumentar para 7,1% ao ano, até 2030 (Microsoft News Center Brasil, 2019).

Andreas Kaplan e Michael Haenlein definem a inteligência artificial como “uma capacidade do sistema para interpretar corretamente dados externos, aprender a partir desses dados e utilizar essas aprendizagens para atingir objetivos e tarefas específicos através de adaptação flexível” (KAPLAN; HAENLEIN, 2019).


Um dos campos da Inteligência Artificial é o Aprendizado de Máquina (*Machine Learning*), que por sua vez pode ser definido como o campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados (SAMUEL, 1967).

Existem duas maneiras de uma máquina aprender, criando duas categorias do *Machine Learning*, sendo elas aprendizagem supervisionada e aprendizagem não supervisionada. Na aprendizagem supervisionada, o cientista de dados é o responsável por monitorar o algoritmo, que irá aprender baseado em conhecimentos e experiências prévias. Resumidamente, que nessa categoria, sabe-se a saída que o algoritmo deve chegar tendo como base uma entrada. Como exemplo, pode-se citar a classificação de imagens e detecção de objetos.

Por outro lado, na aprendizagem não supervisionada, não existe um resultado específico esperado e o algoritmo irá aprender com base nos próprios dados que estão sendo processados. Em geral, necessita-se de um maior volume dados. Como exemplo, pode-se citar o processamento de linguagem natural para criação de legendas automáticas.

Por fim, dentre outras abordagens do *Machine Learning*, encontra-se o Aprendizado Profundo (*Deep Learning*), objeto de estudo deste trabalho, que é capaz de resolver problemas do mundo real por meio de redes neurais artificiais certas vezes com mais precisão e velocidade do que humanos.

Figura 1 – Inteligência artificial, aprendizado de máquina e aprendizado profundo



Fonte: Arquivo dos autores (2020)

2.4 *Deep Learning* e Redes Neurais

2.4.1 História

O início da história do *deep learning* data de 1943, quando o matemático Walter Pitts e o neurofisiologista Warren McCulloch, baseando-se em pesquisas do cérebro humano, modelaram o primeiro modelo computacional para uma rede neural, baseando-se em neurônios simples, criados a partir de circuitos elétricos. Walter e Warren utilizaram uma combinação de matemática e algoritmos, denominada de lógica de limiar (*threshold logic*), que é utilizada até os dias atuais como base das redes neurais (ACADEMY, 2019).

Em 1960, Henry J. Kelley desenvolveu o conceito básico de um modelo de retropropagação (*backpropagation*) (FOOTE, 2019), que também é utilizado até os dias atuais para o recálculo dos pesos das redes neurais no processo de aprendizagem. Apesar das descobertas e estudos nas décadas entre 40 a 80, devido à limitação computacional existente na época, o aprimoramento das redes neurais foi severamente impactado até 1981 e o assunto foi subestimado e criticado, além de ter sofrido grande redução no financiamento de pesquisas relacionadas à área.

Entretanto, em 1982, John Hopfield apresentou uma abordagem prática para redes neurais, demonstrando como elas poderiam atuar em problemas reais, o que fez com que o assunto voltasse a ter sua devida atenção. Em 1987 ocorreu a primeira Conferência Internacional sobre Redes Neurais do *Institute of Electrical and Electronic Engineer's* (IEEE). Ao mesmo

tempo que o assunto vinha novamente ganhando destaque, o poder computacional da época ainda não conseguia acompanhar o desenvolvimento dos estudos, impossibilitando a criação de grandes aplicações com *deep learning*, o que gerou frustração e novamente uma redução de investimentos na área (ACADEMY, 2019).

Ainda assim, algumas pessoas continuaram estudando o assunto e em 1995, Dana Cortes e Vladimir Vapnik desenvolveram a máquina de vetores de suporte, um sistema capaz de reconhecer padrões com aprendizado supervisionado (FOOTE, 2019). Nos anos seguintes, a partir de 1999, os computadores começaram a ganhar poder de processamento, viabilizando a implementação de redes neurais mais eficientes, que começaram a competir com as máquinas de vetores de suporte. Apesar de possuírem um maior tempo de processamento, em geral, as redes neurais se mostraram mais assertivas utilizando os mesmos dados e voltaram a ganhar visibilidade no mercado.


A partir de então diversos estudos e pesquisas realizados na área e à medida que os computadores foram evoluindo, as aplicações envolvendo redes neurais também o fizeram. Nos anos subsequentes, o algoritmo de aprendizagem profunda do Google foi capaz de identificar gatos em 2012 e em 2014 o Facebook implementou a *DeepFace*, tecnologia capaz de marcar automaticamente os rostos dos usuários da rede social em fotografias. Dois anos depois, o algoritmo do Google *AlphaGo* mapeou o jogo de tabuleiro *Go* e ganhou de Lee Sedol em um torneio em Seul, que à época tinha sido campeão mundial de *Go* 18 vezes (ACADEMY, 2019).

Com isso, o campo da inteligência artificial e do *deep learning* em especial vem avançando em pesquisas até os dias atuais, além de novamente ter ganhado visibilidade e estar inserido em diversas aplicações corporativas que requerem uma análise de dados mais profunda, com reconhecimento de padrões, previsões ou classificações, por exemplo.

2.4.2 Funcionamento das Redes Neurais

O funcionamento das redes neurais atuais pode ser explicado tendo como base o perceptron elementar, o modelo mais simples e didático de rede neural de camada única.

Figura 2 – Perceptron Elementar




Fonte: UFSC, s.d. (<https://www.gsigma.ufsc.br/~popov/aulas/rna/neuronio_implementacao/>)

No modelo apresentado (Figura 2), constituído por apenas um único neurônio artificial, duas entradas, uma unidade de *bias* e uma saída, cada entrada possui pesos w_0 , w_1 e w_2 associados a elas, assim como a unidade de *bias*, que também funciona como uma entrada, mas possui seu valor fixado normalmente em 1 ou -1, com a finalidade de aumentar o grau de liberdade do ajuste dos pesos. Por padrão, em bibliotecas que possibilitam a implementação de redes neurais, a unidade de *bias* já é definida automaticamente.

Assim sendo, o algoritmo que simula o neurônio irá multiplicar cada entrada por seu respectivo peso para todas as entradas e realizar a somatória de todos esses resultados. Após a obtenção do valor da somatória, ele deve ser submetido a uma função de ativação ou transferência T , gerando a saída y . Dentre outras funções de transferência, pode-se citar a função sigmoide, tangente hiperbólica, unidade linear retificada (ReLU) e unidade linear exponencial (ELU) (FACURE, 2017).

Durante os estudos e desenvolvimento de algoritmos para redes neurais, ficou claro que para problemas mais complexos, seria necessário expandir a quantidade de neurônios e de camadas, tornando a saída de um neurônio, a entrada para o próximo. A quantidade de neurônios e de camadas deve ser estudada e testada individualmente para cada problema que se pretende solucionar, variando caso a caso.

Figura 3 – Rede Neural Multicamada



Fonte: Arquivo dos autores (2020)

As redes neurais artificiais multicamadas são divididas basicamente em três principais partes: entradas, camadas ocultas e saída, podendo ser uma ou várias dependendo do tipo de problema. Nesse tipo de rede, uma série de neurônios são interligados como mostrado e quando uma saída é obtida, ela é comparada com uma saída considerada correta, gerando um valor de erro. Com base nesse erro, os pesos são então recalculados utilizando o conceito de gradiente para a minimização do erro, até que seu valor seja considerado satisfatório. Essa etapa em que os pesos são recalculados e a rede neural está sofrendo alterações é denominada de treinamento.

Após essa fase, a rede deve ser testada com dados diferentes dos que foram usados durante o treinamento para garantir sua assertividade. Essa etapa recebe o nome de teste. Caso comprovada sua eficiência e as taxas de erro permanecerem baixas, a rede neural está apta para ser utilizada com dados novos obtidos de um contexto real.

2.5 Análise de imagens de câmeras de ônibus

Com o avanço da tecnologia nos últimos anos, pode-se observar o surgimento de algumas aplicações envolvendo a interpretação de imagens das câmeras em transportes públicos. Em 2014, por exemplo, um grupo da Universidade de Parma, Itália, divulgou um artigo (BERNINI et al., 2014) sobre um estudo de contagem de passageiros em ônibus utilizando câmeras que seriam instaladas sobre as portas dos veículos e enviaram as imagens para um computador a bordo capaz de processar as imagens e reconhecer a cabeça das pessoas, realizando uma comparação com esferas. Contudo, esse processo ainda necessitava de melhorias devido à similaridade de outros

objetos com esferas, resultando em falsos positivos e ao seu tempo de processamento, que levava 100 ms.

Em 2019, outra aplicação de análise de imagens no transporte público pode ser citada. Em Bangalore, Índia, um diretor do BMTC (Bengaluru Metropolitan Transport Corporation), órgão responsável pelos ônibus da cidade, anunciou que iniciaria testes em conjunto com Instituto Indiano de Ciência (IISc) nos quais dados provenientes de câmeras instaladas nos ônibus iriam ser enviados para servidores e certos comportamentos do motorista como velocidade e sono seriam analisados (PRASAD, 2019).

Além disso, em maio de 2020, foi implantado nas câmeras dos ônibus da França um sistema que permite analisar o uso de máscaras e o distanciamento social dentro dos veículos como tentativa de prevenir o contágio em meio a crise de Covid-19 (BBC, 2020). A iniciativa partiu da *startup* Datakalab, que garante a privacidade dos passageiros e afirma que o algoritmo não realiza detecção facial, analisando apenas as informações necessárias e avisando as autoridades quando necessário.

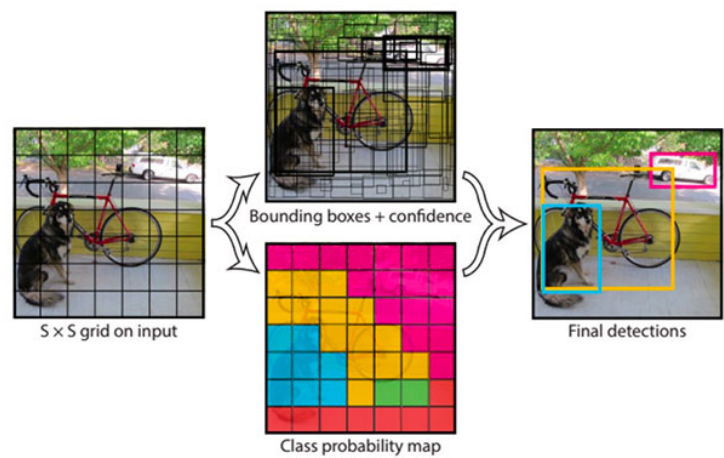
2.5.1 Detecção de objetos em tempo real com YOLO

A lotação dos ônibus é um fator determinante para o ajuste correto das frotas de ônibus e dentre outras informações, será um importante indicativo presente no *dashboard* que será desenvolvido neste trabalho. Uma das maneiras de se extrair essa informação é a partir de uma análise baseada em inteligência artificial das imagens de câmeras instaladas dentro dos veículos, disponibilizadas em tempo real.

Em comparação com outros detectores de imagem, o YOLO, do inglês *You Only Look Once* (você só olha uma vez), se mostrou uma ferramenta extremamente rápida e com alta acuracidade (Redmon, Joseph and Farhadi, 2018), que utiliza um método que analisa a imagem apenas uma vez para realizar a detecção de objetos, dando origem ao seu nome e garantindo sua rapidez.

O funcionamento do YOLO baseia-se em redes neurais convolucionais (Redmon, Joseph and Farhadi, 2018), um tipo específico de rede neural, e inicia-se dividindo a imagem em uma malha $S \times S$ contendo um determinado número de células. Em seguida, cada célula torna-se responsável por criar caixas delimitadoras de objetos, assim como prever a probabilidade dessas caixas conterem um objeto em específico. A partir disso, um mapa com diversas caixas delimitadoras é criado para a imagem, contendo a localização de cada objeto detectado. Contudo, muitas destas caixas possuem precisão muito baixa e então apenas as com maior precisão são mantidas. A Figura 4 representa esse funcionamento.


Figura 4 – Etapas da detecção de objetos do YOLO



Fonte: Rosebrock, Adrian, 2018 (<<https://www.pyimagesearch.com/2018/11/12/yolo-object-detection-with-opencv/>>)

Por fim, vale ressaltar que o YOLOv3, versão mais nova da ferramenta disponível atualmente, quando comparado com outras ferramentas de mesma finalidade apresenta em média uma precisão parecida na escala mAP-50 (utilida para medir a precisão dos algoritmos de reconhecimento de imagens), porém sua velocidade de processamento é maior, chegando a ser quatro vezes mais rápido (Figura 5). Assim sendo, para análise de imagens em tempo real, nas quais a velocidade é crucial, o YOLO revela-se uma excelente alternativa.

Figura 5 – Comparação do YOLO com outras ferramentas



Fonte: Redmon, Joseph e Farhadi, Ali, 2018 (<<https://pjreddie.com/darknet/yolo/>>)

2.6 Análise de Dados

Apesar de estar cada vez mais em destaque nestes últimos anos, podemos traçar o uso de estatística para tomada de decisão desde do Egito Antigo, de acordo com um artigo publicado por Keith D. Foote (FOOTE, 2018) os egípcios já usavam cálculos estatísticos para construir as pirâmides. Já na década de 1880, o governo americano levou pelo menos 7 anos para completar o censo da população, processo que foi reduzido para um ano e meio na década seguinte por causa do desenvolvimento de uma máquina de tabulação, por Herman Hollerith, que processava os dados de forma sistêmica em cartões perfurados.

2.6.1 Primeira fase da análise de dados

Trazendo para os dias atuais, a Universidade de Villanova separa a análise de dados em três estágios (VILLANOVA, s.d.). O primeiro deles seria o início do que chamamos de *Business Intelligence*, que surgiu por volta de 1950 como uma forma de processar pequenas quantidades de informações estruturadas. Esse estágio, que podemos chamar de *Analytics 1.0*, durou até cerca de 2009, quando foi consolidado o termo "*big-data*".

O fim do primeiro estágio se deu pelo aumento exponencial de dados sendo produzidos diariamente, podendo vir de qualquer lugar e forma, desde de informações simples e estruturadas, como quais produtos alguém comprou em um determinado site, ou coisas mais complexas, como quais sites fizeram essa pessoa chegar até uma determinada página e qual a posição geográfica dessa pessoa quando acessou a página. Se convencionou a chamar esses dados em grande quantidade e pouco estruturados de "*big-data*".

2.6.2 Segunda fase da análise de dados

Pela dificuldade de armazenar e processar essa massiva quantidade de dados, se fez necessário o desenvolvimento de novos métodos e ferramentas para o processamento deles, o que deu início ao *Analytics 2.0*, que trouxe alternativas como Hadoop, que pode processar essas grandes massas de dados, e o NoSQL, que permite armazenar toda a informação de forma mais eficiente que os bancos de dados relacionais faziam até então. Além disso, cada vez mais se fez necessário um conhecimento tecnológico para fazer essas análises, quando até então bastava o conhecimento de métodos estatísticos.

2.6.3 Terceira fase da análise de dados

Hoje em dia, muitos especialistas dizem que chegamos a um terceiro estágio, o *Analytics 3.0*, onde esses dados que são produzidos a qualquer momento podem ser usados como moeda de troca entre consumidor e fornecedor. Essa moeda pode ser analisada imediatamente pelo

fornecedor, que passa a entregar uma experiência personalizada para quem está consumindo o seu produto.

2.6.4 Análise de dados no dia a dia

Com a disponibilidade de dados que temos, as empresas estão se dedicando cada vez mais em coletar e auxiliar as suas decisões nas análises feitas com eles. O Diretor de Estratégia e Marketing de Precisão da Coca-Cola, Justin De Graaf, afirmou em entrevista para ADMA, Association for Data-Driven Marketing & Advertising, que cada vez mais a empresa usa informações coletadas diretamente dos consumidores, como por meio de telefone, redes sociais ou *e-mail*, para criar desde campanhas publicitárias até novos produtos (TAN, 2017). Outra marca consolidada usando análise de dados para a tomada de decisão é a rede de hotéis Marriott, que, de acordo com o seu *chief development officer*, Eric Jacobs, tem usado esse tipo de informação para decidir como identificar, atrair e manter os seus cliente mais lucrativos (EISEN, 2018). Para isso eles coletam desde dados como padrão social dos clientes até se eles consomem mais jeans Levi's ou Gap.

Apesar disso, alguns resultados dessas análises podem ter um efeito contrário do que era pretendido no início. Caso a análise não seja feita com atenção, verificando sempre quem está sendo atingido, ela pode levar a alguns atritos e desgastar a imagem de quem usa essas informações.


Em 2012, o New York Time publicou uma história de como um pai descobriu a gravidez da filha através de uma promoção oferecida pela rede varejista Target, nos Estados Unidos (DUHIGG, 2012). Andrew Pole, um estatístico da rede, foi designado para desenvolver um "preditor de gravidez", no fim do estudo ele conseguiu chegar a uma lista de 25 produtos, que geram uma probabilidade da cliente estar grávida de acordo com o seu preditor. Esses produtos contêm itens como manteiga de cacau, bolsas grandes o suficiente para caber pacotes de fraldas, e suplementos como magnésio e zinco.

A Target vinculava essa informação a um identificador do cliente, e então ofereceria um desconto na próxima visita que essa mesma pessoa fizesse a loja. Um ano após a aplicação deste preditor, o pai de uma adolescente foi a uma das lojas reclamar que sua filha tinha recebido um desconto relacionado a esse programa específico para grávidas, com isso, o gerente da loja se desculpou pelo erro e alguns dias depois ligou para se desculpar novamente. Entretanto, para a surpresa do gerente, durante essa ligação o cliente disse que a filha não tinha contado para ele que estava grávida, e que a Target soube antes dele do acontecido. Após esse caso, o departamento de *marketing* decidiu desacelerar o programa de análises de dados, e passar mais tempo avaliando qual impacto cada iniciativa pode ter.

3 Metodologia

A fim de solucionar o problema identificado, foram definidos métodos e estratégias com o objetivo de criar um fluxo de trabalho. A figura 6 fornece um diagrama ilustrativo e simplificado da solução proposta.

Figura 6 – Ilustração da solução



Fonte: Arquivo dos autores (2020)

Primeiramente alguns dados dos ônibus como, por exemplo, velocidade, tempo de parada, linhas, posição dos veículos são coletados juntamente com imagens do interior dos veículos, que passam por um algoritmo de reconhecimento para identificar a lotação dos mesmos. Paralelamente, informações obtidas por meio de APIs externas enriquecem o conjunto de dados, que por sua vez passa por um tratamento e um treinamento. Após esse processo algumas informações são direcionadas diretamente para o painel de controle enquanto outras passam pela inteligência artificial para depois serem colocadas no *dashboard*.

3.1 Aquisição de dados externos por meio de tarefas

No que diz respeito à aquisição de dados para alimentação do *dashboard* e sucessiva análise, foi utilizada como principal fonte, a API pública da SP-Trans, mais especificamente

os *endpoints* (SCHULTZ, 2020) “Parada”, “Posicao” e “KMZ”. Cada *endpoint* é responsável por trazer informações como as paradas dos corredores dos ônibus de São Paulo, a posição dos veículos, assim como sua respectiva linha e frota em um dado instante e um arquivo (TECHTUDO, 2016) contendo informações de velocidade das linhas, respectivamente.

Vale ressaltar que para a aquisição dos dados do arquivo KMZ, foi realizada uma quebra do arquivo, que originalmente possui as informações em formato XML (MAGALHAES, 2020). Esse procedimento foi necessário para obter todas as informações já tratadas do arquivo em formato JSON (JSON, 2020) para carga do banco de dados.

Adicionalmente a API da SP-Trans, são coletados dados de outras fontes, como Climatempo, Direto dos Trens e *Tickets for Fun*, que são responsáveis por dados como condições meteorológicas, situação das linhas de trens e metrô em tempo real e localização e data de eventos, respectivamente.

Tendo em vista que todos os dados são coletados com informações em tempo real, é necessário que eles sejam armazenados para que se construa um histórico a fim de se analisar os dados futuramente. Com esse objetivo, foi utilizado o Celery (CELERY, 2018), um módulo Python que permite a criação de tarefas assíncronas e agendadas. Tais tarefas foram modeladas para coletar as informações das fontes mencionadas anteriormente em um determinado período de tempo de forma assíncrona e salvá-las em um banco de dados PostgreSQL (POSTGRESQL, 2020), criado exclusivamente para o projeto.

Paralelamente à utilização do Celery, foi utilizado um serviço da AWS (AWS, 2020), o *Amazon Simple Queue Service* (SQS), que recebe as tarefas agendadas do Celery e as administra em uma fila, enviando novamente para execução quando for a hora certa. Dessa maneira, as informações em tempo real passaram a ser extraídas ciclicamente por meio das tarefas e salvas em um banco de dados dedicado, gerando um histórico para análise.


3.2 Criação de gráficos com Django

Para a criação do *dashboard* do projeto que exibe informações extraídas a partir dos dados disponíveis no banco de dados, foi utilizado o Django (DJANGO, 2020), um *framework* Python de desenvolvimento rápido para *web*.

O Django utiliza o padrão *model-template-view*, que fornece todas as ferramentas necessárias para o desenvolvimento *web*, desde a criação de um modelo associado ao banco de dados, até o processamento de requisições e criação de páginas *web* dinâmicas de forma robusta e simples. Um de seus principais diferenciais é a padronização dos aplicativos e portabilidade dos mesmos para outros projetos. Isso possibilita uma fácil implementação de módulos e aplicativos externos.

Assim sendo, um dos principais aplicativos utilizados nesse projeto foi o *django-plotly-dash*, que possibilita uma fácil criação de gráficos e painéis que são atualizados em tempo real utilizando apenas código Python, sem a necessidade de escrever código HTML, CSS ou Javascript. Isso possibilitou uma integração direta dos modelos criados no Django com os gráficos. A figura 7 mostra alguns exemplos de gráficos desenvolvidos com o *django-plotly-dash* para o projeto.

Figura 7 – Gráficos criados pelo *django-plotly-dash*



Fonte: Arquivo dos autores (2020)

Quanto aos modelos mencionados anteriormente, foi criado um modelo para cada informação extraída das APIs externas, estando eles associados à posição dos ônibus, velocidade das vias, linhas e paradas de ônibus, informações das linhas de trens e metrô, informações meteorológicas e eventos. Todos os modelos estão associados a um banco de dados PostgreSQL, que por possuir uma melhor integração com Python e Django, além de se tratar de um banco de dados relacional e rápido, foi a opção escolhida para o projeto.

3.3 APIs com Django REST *Framework*

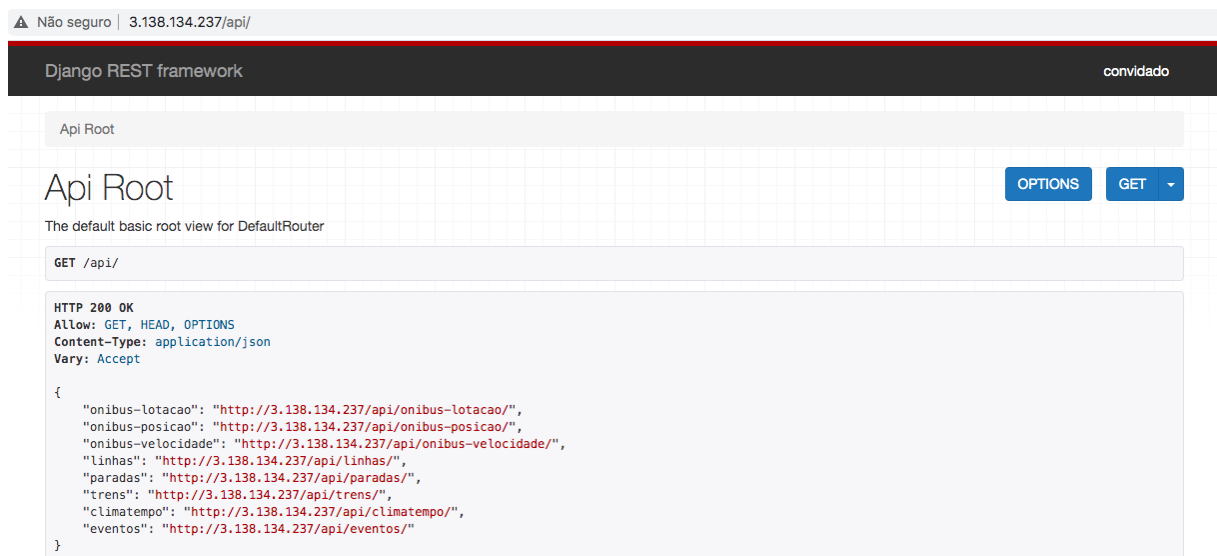
O Django REST *Framework* é uma biblioteca para o *Framework* Django que disponibiliza funcionalidades para implementar APIs REST de forma extremamente rápida e fácil. É extremamente simples configurar e criar rotas que aceitam todos os verbos HTTP se comu-

nicando diretamente com o banco de dados e atendendo ao CRUD (*Create* (Criação), *Read* (Consulta), *Update* (Atualização) e *Delete* (Destruição)) (ESTEVAO, 2016).


Outra grande vantagem, além da facilidade de implementação, é a criação automática de uma plataforma *web* que centraliza todas as possibilidades de requisições de todas as rotas disponíveis. Nela é possível escolher a forma que deseja visualizar os dados, seja como JSON ou XML o tipo de retorno.

Com as API's implementadas, é possível acessar os dados da aplicação de forma independente do *dashboard*. Assim, outras pessoas podem ter acesso a esses dados para novas e futuras análises. Alguns dos *endpoints* criados disponibilizam dados como de velocidade, posição, linhas, paradas, metrô, trem e clima.

Figura 8 – Rotas das APIs dentro da plataforma *web* disponibilizada pelo Django



Fonte: Arquivo dos autores (2020)

Figura 9 – Exemplo de retorno JSON do *endpoint* /api/onibus-lotacao

Fonte: Arquivo dos autores (2020)

Na figura 8, podemos visualizar uma lista com todas as rotas disponíveis. Um exemplo de requisição nessas rotas pode ser visualizado na imagem 9, onde é realizada uma requisição do tipo *GET* no *endpoint* 'onibus-lotacao'.

Podemos ver que a resposta foi do tipo JSON, retornando todas as informações disponíveis como, id, id_onibus, id_linha, lotação, latitude, longitude, data_inclusao.

3.4 Endpoints

Na imagem 8, podemos visualizar todos os *endpoints* disponíveis, cada um deles possui suas informações e funções. No apêndice A, uma breve descrição de cada uma delas, e como utilizá-las com os verbos *GET* e *POST*, assim como uma prévia do retorno das informações.

Foi escolhido apresentar as requisições *GET* e *POST* pois são através delas que o

dashboard consome os dados e que as APIs externas salvam as informações dentro do nosso banco de dados.

3.5 Infraestrutura de nuvem

Pela necessidade de estar disponível a qualquer momento e de capturar o máximo de informação possível, decidimos disponibilizar o nosso sistema na nuvem, utilizando a plataforma da Amazon, principalmente os recursos da *Elastic Cloud Compute* (EC2). A nossa infraestrutura gira em torno de uma máquina Linux, da categoria t2.medium, que se provou o mínimo necessário para executar o nosso sistema e aguentar a carga de algumas visitas simultâneas.

Começando pela máquina, as instâncias EC2 t2.medium são máquinas com 2 núcleos dedicados, 4GB de memória RAM, indicadas tanto para o uso como plataforma de desenvolvimento quanto para servidores *web*. Entre suas características temos processadores com um *clock* relativamente alto e ao mesmo tempo um custo baixo em comparação com as outras soluções oferecidas pela Amazon, como instâncias t3 ou A1.

Decidimos usar a instância t2.medium após realizar testes tanto com a t2.micro, que é gratuita para as 750 primeiras horas por mês, quanto a t2.small, que é totalmente paga, mas mais econômica que a t2.medium. A modalidade micro apresentou dificuldades logo nos primeiros instantes, apesar de ser capaz de executar o *dashboard* em Django paralelo ao banco de dados PostgreSQL, quando começamos a rodar as tasks do Celery para captura de dados, o processamento disponível para ela não foi o suficiente, atingindo 100% de uso do núcleo disponível e deixando o sistema inutilizável, mesmo com uma única pessoa acessando. Já a instância t2.small se mostrou capaz de executar as *tasks* simultaneamente ao *dashboard* e o banco de dados, porém ao começar a receber acessos no *dashboard* o sistema não conseguia dar conta das requisições e apresentava uma constante lentidão.

Com isso, chegamos a conclusão que a instância mínima para rodarmos o nosso projeto com segurança é a t3.medium, e mesmo assim rapidamente consumimos todo o seu armazenamento em pouco menos de uma semana, após isso expandimos ele de 7GB para 50GB, o que nos daria uma margem de segurança até a conclusão do projeto. Apesar da instância média ser o suficiente para o nosso uso durante o desenvolvimento, notamos que a sua configuração não seria o suficiente para um momento de fluxo constante no sistema por conta do uso do processador, que se aproxima de 100% sempre que tem mais de dois navegadores acessando simultaneamente, por isso durante o Eureka, decidimos usar a instância t2.2xlarge, com 8 vCores e 32GB de memória ram, o que se mostrou suficiente para momentos com cerca de 10 acessos simultâneos.

Para o acesso à instância pelo navegador, usamos uma implantação simples do NGINX (NGINX, 2020), um servidor web muito popular por sua facilidade de uso e segurança. O servidor é o primeiro lugar que as requisições web chegam na instância e o NGINX distribui

essas requisições para cada local definido em suas configurações, na nossa situação temos uma rota só para os arquivos estáticos e outra para o sistema em si. Isso permite uma velocidade de resposta maior que se todos os elementos estivessem na mesma rota e facilita a manutenção dos arquivos do sistema.

4 Resultados Obtidos

4.1 Resultados

5 Conclusão e Trabalhos futuros

5.1 Conclusão

5.2 Trabalhos Futuros

Apêndices

APÊNDICE A – *ENDPOINTS*

A.1 */api/onibus-lotacao/*

GET

```
{
  "id": 1,
  "id_onibus": 96587,
  "id_linha": 2215,
  "lotacao": "cheio",
  "latitude": "45.658000000000001",
  "longitude": "12.987000000000000",
  "data_inclusao": "2020-10-09T19:41:53.075905Z"
}
```

POST

```
{
  "img": caminho_img,
  "id_onibus": id_onibus,
  "id_linha": id_linha,
  "latitude": latitude,
  "longitude": longitude
}
```

A.2 */api/onibus-posicao/*

GET

```
{
  "quantidade": 11992
}
```

POST

```
{
  "o": [
    {
      "id_onibus": id_onibus,
      "onibus_deficiente": onibus_deficiente,
      "horario_atualizacao_localizacao": horario_atualizacao_localizacao,
      "latitude": latitude,
      "longitude": longitude,
      "id_linha": id_linha,
      "frota": frota,
    }
  ]
}
```

A.3 */api/onibus-velocidade/*

GET

```
{
  "id": 1067508,
  "nome": "BUTANTA (BAIRRO - CENTRO)",
  "vel_trecho": 27,
  "vel_via": 27,
  "trecho": "de R. AMARO CAVALHEIRO ate R. PAES LEME",
  "extensao": 650,
  "tempo": "00:01",
  "coordenadas": [
    {
      "latitude": "-23.567653",
      "longitude": "-46.695722",
      "id": 6217
    },
    {
      "latitude": "-23.568001",
      "longitude": "-46.696452",
      "id": 6218
    },
    {
      "latitude": "-23.568063",
      "longitude": "-46.696595",
      "id": 6219
    }
  ]
}
```

POST

```
{
  "o": [
    {
      "name": nome,
      "description": {
        'vel_trecho': vel_trecho,
        'vel_via': vel_via,
        'trecho': trecho,
        'extensao': extensao,
        'tempo': tempo
      },
      "coordinates": {
        'lat': latitude,
        'lon': longitude
      }
    }
  ]
}
```

A.4 /api/linhas/

GET

```
{
  "id_linha": 264,
  "letreiro": "509J-10",
  "sentido": 1,
  "letreiro_destino": "PQ. IBIRAPUERA",
  "letreiro_origem": "JD. SELMA"
}
```


POST

```
{
  "l": [
    {
      "id_linha": id_linha,
      "letreiro": letreiro,
      "sentido": sentido,
      "letreiro_destino": letreiro_destino,
      "letreiro_origem": letreiro_origem,
    }
  ]
}
```

A.5 /api/paradas/*GET*

```
{
  "id": 1,
  "id_parada": 4203724,
  "nome": "",
  "endereco": "R. Agamenon Pereira da Silva",
  "latitude": "-23.6928650000000001",
  "longitude": "-46.7783500000000003"
}
```

POST

```
{
  "p": [
    {
      "id_parada": id_parada,
      "nome": nome,
      "endereco": endereco,
      "latitude": latitude,
      "longitude": longitude,
    }
  ]
}
```

A.6 /api/trens/*GET*

```
{
  "id": 1,
  "id_linha": 1,
  "data_ocorrencia": "2020-10-07T07:42:01.039607Z",
  "descricao": null,
  "ultima_atualizacao": "2020-10-07T21:14:01.162598Z",
  "situacao": "Operacao Normal"
}
```

POST

```
{
  "t": [
    {
      "id_linha": id_linha,
      "data_ocorrencia": data_ocorrencia,
      "descricao": descricao,
      "ultima_atualizacao": ultima_atualizacao,
      "situacao": situacao,
    }
  ]
}
```

A.7 /api/climatempo/

GET

```
{
  "id_cidade": 3477,
  "temperatura": "27.00",
  "direcao_vento": "S",
  "velocidade_vento": "9.00",
  "umidade": "66.00",
  "condicao": "Nuvens esparsas",
  "pressao": "1015.00",
  "sensacao": "28.00",
  "date": "2020-10-07T21:14:34.451818Z"
}
```

POST

```
{
  "ct": [
    {
      "id_cidade": id_cidade,
      "temperatura": temperatura,
      "direcao_vento": direcao_vento,
      "velocidade_vento": velocidade_vento,
      "umidade": umidade,
      "condicao": condicao,
      "pressao": pressao,
      "sensacao": sensacao,
    }
  ]
}
```

A.8 /api/eventos/

GET

```
{
  "id": 26,
  "nome": "Maria Bethania",
  "link": "http://premier.ticketsforfun.com.br/shows/show.aspx?sh=MARIBUB19",
  "data_info": "Sao Paulo no UnimedHall 27 de junho",
  "data": "2020-06-27",
  "endereco": "Av. das Nacoes Unidas, 17955 - Vila Almeida, Sao Paulo - SP, 04795-100, Brazil",
  "latitude": "-23.647672600000000",
}
```

```
"longitude": "-46.723812100000004",  
"data_inclusao": "2020-10-14T00:17:58.612131Z"  
}
```

POST

```
{  
  "e": [  
    {  
      "nome": nome,  
      "link": link,  
      "data_info": data_info,  
      "data": data,  
      "endereco": endereco,  
      "latitude": latitude,  
      "longitude": longitude  
    }  
  ]  
}
```

Referências

- ACADEMY, D. S. **Deep Learning Book**. 2019. Disponível em: <<http://www.deeplearningbook.com.br/>>. Acesso em: 2020-05-12. 20, 21
- ACCENTURE. **Country Spotlights: Why Artificial Intelligence Is the Future of Growth**. [S.l.], 2016. 19
- AWS. **Amazon Web Services (AWS) Serviços de computação em nuvem**. 2020. Disponível em: <<https://aws.amazon.com/pt/>>. 29
- BBC. **Coronavirus France: Cameras to monitor masks and social distancing - BBC News**. 2020. Disponível em: <<https://www.bbc.com/news/world-europe-52529981>>. Acesso em: 2020-05-11. 24
- Ben Ayed, A.; Ben Halima, M.; ALIMI, A. M. Big data analytics for logistics and transportation. **2015 4th IEEE International Conference on Advanced Logistics and Transport, IEEE ICAIT 2015**, p. 311–316, 2015. 16
- BERNINI, N.; BOMBINI, L.; BUZZONI, M.; CERRI, P.; GRISLERI, P. An embedded system for counting passengers in public transportation vehicles. **MESA 2014 - 10th IEEE/ASME International Conference on Mechatronic and Embedded Systems and Applications, Conference Proceedings**, 2014. 23
- CELERY. **Celery - Distributed Task Queue — Celery 5.0.2 documentation**. 2018. Disponível em: <<https://docs.celeryproject.org/en/stable/>>. 29
- DEMORA. **Demora do ônibus**. 2018. Disponível em: <https://www.reclameaqui.com.br/sptrans/demora-do-onibus_3dNERaztrwT9ckEK/>. 14
- DEMORA. **Demora da linha**. 2020. Disponível em: <https://www.reclameaqui.com.br/sptrans/demora-da-linha_AZuNpkdOrYwgBj-z/>. 14
- DJANGO. **The Web framework for perfectionists with deadlines Django**. 2020. Disponível em: <<https://www.djangoproject.com/>>. 29
- DUHIGG, C. **How Companies Learn Your Secrets**. 2012. Disponível em: <https://www.nytimes.com/2012/02/19/magazine/shopping-habits.html?pagewanted=1&_>. Acesso em: 2020-04-26. 27
- EISEN, D. **Marriott bets on predictive analytics for brand growth**. 2018. Disponível em: <<https://www.hotelmanagement.net/tech/marriott-builds-its-brands-by-knowing-more-about-you>>. Acesso em: 2020-04-26. 27
- ESTEVAO. **Principais verbos HTTP utilizados em um serviço REST**. 2016. Disponível em: <<https://www.devmedia.com.br/servicos-restful-verbos-http/37103>>. 31
- FACURE, M. **Funções de ativação**. 2017. Disponível em: <<https://matheusfacure.github.io/2017/07/12/activ-func/>>. 22
- FOOTE, K. D. **A Brief History of Analytics**. 2018. Disponível em: <<https://www.dataversity.net/brief-history-analytics/>>. Acesso em: 2020-04-26. 26

- FOOTE, K. D. **A Brief History of Deep Learning - DATAVERSITY**. 2019. Disponível em: <<https://www.dataversity.net/brief-history-deep-learning/>>. 20, 21
- G1. **Pesquisa traça perfil dos usuários do transporte público em São Paulo**. 2013. Disponível em: <<http://g1.globo.com/sao-paulo/anda-sp/noticia/2013/06/pesquisa-traca-perfil-dos-usuarios-do-transporte-publico-em-sao-paulo.html>>. 14
- INTELIPOST. **A importância do dashboard para e-commerce**. 2017. Disponível em: <<https://www.intelipost.com.br/blog/a-importancia-do-dashboard-para-e-commerce/>>. Acesso em: 2020-04-28. 17
- JSON. **JSON**. 2020. Disponível em: <<https://www.json.org/json-pt.html>>. 29
- KAPLAN, A.; HAENLEIN, M. Siri, Siri, in my hand: Who's the fairest in the land? On the interpretations, illustrations, and implications of artificial intelligence. **Business Horizons**, p. 15–25, 2019. 19
- KLEVERTON. **O que é UX – User Experience**. 2019. Disponível em: <<https://www.intelipost.com.br/blog/a-importancia-do-dashboard-para-e-commerce/>>. Acesso em: 2020-05-01. 19
- LEE, I. Big data: Dimensions, evolution, impacts, and challenges. **Business Horizons**, "Kelley School of Business, Indiana University", v. 60, n. 3, p. 293–303, 2017. ISSN 00076813. Disponível em: <<http://dx.doi.org/10.1016/j.bushor.2017.01.004>>. 16
- LOBO, R. **Top 10 das linhas de ônibus mais movimentadas de São Paulo**. 2013. Disponível em: <<https://viatrolebus.com.br/2013/07/top-10-das-linhas-de-onibus-mais-movimentadas-de-sao-paulo/>>. 14
- MAGALHAES, A. **O que é e para que serve o arquivo XML Canaltech**. 2020. Disponível em: <<https://canaltech.com.br/software/xml-o-que-e/>>. 29
- Microsoft News Center Brasil. **Com Inteligência Artificial, Brasil pode quadruplicar crescimento da produtividade e aumentar PIB em até 7,1% ao ano, diz estudo - Microsoft News Center Brasil**. 2019. Disponível em: <<https://news.microsoft.com/pt-br/com-inteligencia-artificial-brasil-pode-quadruplicar-crescimento-da-produtividade-e-aumentar-pib-em-ate-71-ao-ano-diz-estudo/>>. Acesso em: 2020-05-11. 19
- NGINX. **NGINX High Performance Load Balancer, Web Server, Reverse Proxy**. 2020. Disponível em: <<https://www.nginx.com/>>. 33
- NTURBANO. **Só 0,01% do Orçamento Federal para o transporte coletivo urbano. Revista NTurbano**, 2019. Disponível em: <<https://www.ntu.org.br/novo/NoticiaCompleta.aspx?idArea=10&idNoticia=1>>. Acesso em: 2020-04-18. 13
- PEDUZZI, P. **Estudo do Ipea mostra que 65% da população usam transporte público nas capitais**. 2011. Disponível em: <<https://memoria.ebc.com.br/agenciabrasil/noticia/2011-05-04/estudo-do-ipea-mostra-que-65-da-populacao-usam-transporte-publico-nas-capitais>>. Acesso em: 2020-04-18. 13
- PENA, R. F. A. **Problemas no transporte público**. s.d. Disponível em: <<https://brasilecola.uol.com.br/geografia/problemas-no-transporte-publico.htm>>. Acesso em: 2020-04-18. 13

POSTGRESQL. **PostgreSQL: The world's most advanced open source database**. 2020. Disponível em: <<https://www.postgresql.org/>>. 29

PRASAD, P. **Bus lanes to go hi-tech with AI, GPS- The New Indian Express**. 2019. Disponível em: <<https://www.newindianexpress.com/cities/bengaluru/2019/oct/19/bus-lanes-to-go-hi-tech-with-ai-gps-2049884.html>>. Acesso em: 2020-05-11. 24

Redmon, Joseph and Farhadi, A. **YOLOv3: An Incremental Improvement**. 2018. Disponível em: <<https://pjreddie.com/darknet/yolo/>>. Acesso em: 2020-05-11. 24

SAMPA, M. **Números da Mobilidade Urbana em São Paulo e região metropolitana**. 2018. Disponível em: <<https://mobilidadesampa.com.br/mobilidade-urbana/>>. 14

SAMUEL, A. L. Some Studies in Machine Learning Using the Game of Checkers. II-Recent Progress. **IBM Journal**, nov 1967. Disponível em: <https://pdfs.semanticscholar.org/9330-/a04e17d3b9ea092bd7dd5295b2d61d53bff5.pdf?_ga=2.40137504.345319255.1589332214-1396141800.1589332214>. 19

SANTOS, G. **Transporte público precisa de R\$ 235 bi em investimento, estima BNDES**. 2015. Disponível em: <<https://www1.folha.uol.com.br/mercado/2015/09/1685379-transporte-publico-precisa-de-r-235-bi-em-investimento-estima-bndes.shtml>>. Acesso em: 2020-04-18. 13

SCHULTZ, F. **O que é um endpoint: Como proteger este tipo de dispositivo Milvus**. 2020. Disponível em: <<https://milvus.com.br/o-que-e-endpoint/>>. 29

SYSTEMSAT. **DASHBOARD OPERACIONAL: TUDO O QUE VOCÊ PRECISA SABER**. s.d. Disponível em: <<https://www.systemsat.com.br/dashboard-operacional/>>. Acesso em: 2020-04-29. 18

TAN, A. **How Coca-Cola uses data to supercharge its superbrand status**. 2017. Disponível em: <<https://www.adma.com.au/resources/how-coca-cola-uses-data-to-supercharge-its-superbrand-status>>. Acesso em: 2020-04-26. 27

TECHTUDO. **Como abrir mapas .KML, .KMZ, .CSV, .TSV, .GPX ou .XLSX no Google Maps | Dicas e Tutoriais | TechTudo**. 2016. Disponível em: <<https://www.techtudo.com.br/dicas-e-tutoriais/noticia/2016/11/como-abrir-mapas-kml-kmz-csv-tsv-gpx-ou-xlsx-no-google-maps.html>>. 29

TECNICON. **5 benefícios do uso de dashboard na gestão empresarial**. 2019. Disponível em: <https://www.tecnicon.com.br/blog/438-5%7B/_%7Dbeneficios%7B/_%7Ddo%7B/_%7Duso%7B/_%7Dde%7B/_%7Ddashboard%7B/_%7Dna%7B/_%7Dgestao%7B/_%7Dempresarial>. Acesso em: 2020-04-24. 17, 18

VIEIRA, M. R.; BARBOSA, L.; KORMÁKSSON, M.; ZADROZNY, B. USapiens: A System for Urban Trajectory Data Analytics. **Proceedings - IEEE International Conference on Mobile Data Management**, v. 1, p. 255–262, 2015. ISSN 15516245. 16

VILLANOVA. **The Evolution of Data Collection and Analytics**. s.d. Disponível em: <<https://taxandbusinessonline.villanova.edu/blog/the-evolution-of-data-collection-and-analytics/>>. Acesso em: 2020-04-26. 26